

R: limpieza, manipulación y exploración de datos

8vo encuentro: Visualización de datos I

Jonatán Perren

26 de mayo de 2026

- **ggplot2 y la gramática de gráficos:** qué es, por qué usarlo, sus componentes
- **El lienzo:** `ggplot()`, `aes()` y el operador `+`
- **Maapeo de estéticas:** variables a propiedades visuales
- **Gráficos de distribución:** `geom_histogram()`, `geom_density()`, `geom_boxplot()`
- **Personalización:** `labs()` y `theme_*`

Paquetes y datos

```
1 library(tidyverse)
2 library(gapminder) # install.packages("gapminder") si no está instalado
3
4 # Filtrar solo el año 2007 para los primeros ejemplos
5 gapminder_2007 <- gapminder > filter(year == 2007)
```

El dataset `gapminder` contiene datos de **142 países** con variables de desarrollo humano y económico: esperanza de vida, población y PBI per cápita, relevados cada 5 años entre 1952 y 2007.

¿Qué es ggplot2?

ggplot2 es una implementación del paradigma **Grammar of Graphics** (Wilkinson, 1999) desarrollada por Hadley Wickham. En lugar de elegir un tipo de gráfico predefinido, se **construye** el gráfico capa por capa especificando sus componentes.

Paradigma	Cómo funciona
Base R	<code>hist(x)</code> , <code>plot(x, y)</code> , <code>boxplot(x)</code> – función distinta para cada tipo
ggplot2	<code>ggplot(datos, aes(x)) + geom_*()</code> – misma estructura para todo

La ventaja de la gramática de gráficos es que cualquier gráfico, por complejo que sea, se construye con los mismos bloques. Aprender la lógica una vez permite hacer cualquier tipo de visualización.

ggplot2 viene incluido en **tidyverse** y se carga automáticamente con `library(tidyverse)`.

Los componentes de un gráfico

Todo gráfico de ggplot2 se compone de **capas**, y cada capa tiene estos elementos:


Componente	Función	Qué define
<code>ggplot()</code>	obligatorio	el lienzo: los datos y el mapeo base
<code>aes()</code>	obligatorio	qué variable va en cada propiedad visual
<code>geom_*()</code>	obligatorio	la forma geométrica que representa los datos
<code>labs()</code>	opcional	títulos, etiquetas de ejes, leyendas
<code>scale_*()</code>	opcional	cómo se transforma o colorea cada escala
<code>facet_*()</code>	opcional	dividir el gráfico en paneles
<code>theme_*()</code>	opcional	el estilo visual general (fondo, grillas, fuentes)

Solo `ggplot()`, `aes()` y al menos un `geom_*()` son estrictamente necesarios. El resto son capas opcionales que se agregan con **+**.

El lienzo: `ggplot()` y `aes()`

`ggplot()` crea el lienzo del gráfico. Recibe los **datos** y el **mapeo estético base**: qué variable va en cada eje o propiedad visual.

```
1 # Solo el lienzo: define ejes pero no dibuja nada todavía  
2 ggplot(data = gapminder_2007, mapping = aes(x = gdpPercap, y = lifeExp))
```




`ggplot()` solo prepara el lienzo con los ejes correctos. Hasta que no se agrega un `geom_*()`, no hay ningún elemento visual que represente los datos.

Agregar geometrías: geom_*()

Para dibujar los datos, se añade una **geometría** con el operador **+**. La geometría define la forma visual: puntos, barras, líneas, cajas, etc.

```
1 ggplot(gapminder_2007, mapping = aes(x = gdpPercap, y = lifeExp)) +  
2   geom_point()
```



El operador **+** **no es el pipe** ▷. En ggplot2, **+** agrega una capa al gráfico. El pipe transforma datos antes de pasarlos a **ggplot()**. Ambos se combinan:
datos ▷ **filter(...)** ▷ **ggplot(aes(...)) + geom_*()**.

Teniendo en cuenta el operador pipe y que `mapping` es también un argumento posicional

```
1  # Casi siempre optaremos por escribir  
2  df ► ggplot(aes(...))  
3  # o  
4  ggplot(df, aes(...))  
5  
6  # en lugar de  
7  ggplot(data = df, mapping = aes(...))  
8
```

Mapeo de estéticas: `aes()`


`aes()` mapea **variables del dataset** a **propiedades visuales**. Cada propiedad visual del gráfico puede representar una variable.

Estética	Tipo de variable	Qué controla
<code>x, y</code>	continua o discreta	posición en cada eje
<code>color</code>	discreta o continua	color del borde o la línea
<code>fill</code>	discreta o continua	color de relleno interior
<code>alpha</code>	continua (0-1)	transparencia
<code>size</code>	continua	tamaño del punto o línea
<code>shape</code>	discreta	forma del punto (círculo, triángulo...)
<code>linetype</code>	discreta	tipo de línea (sólida, punteada...)


```

1 # Agregar una tercera variable al gráfico de dispersión:
2 gapminder_2007 > ggplot(aes(x = gdpPerCap, y = lifeExp, color = continent)) +
3   geom_point()
4

```



Estéticas globales vs. locales

Las estéticas definidas en `ggplot(aes())` son **globales**: se aplican a todas las capas. Las definidas dentro de un `geom_*(aes())` son **locales**: solo afectan a esa capa.

```
1 # Global: color se aplica a todos los geoms del gráfico
2 ggplot(gapminder_2007, aes(x = gdpPercap, y = lifeExp,
3                             color = continent)) +
4   geom_point()
5
6 # Local: color solo en geom_point, no en otras capas que se agreguen
7 ggplot(gapminder_2007, aes(x = gdpPercap, y = lifeExp)) +
8   geom_point(aes(color = continent))
```

Valores fijos vs. mapeo de variables


```
1 # DENTRO de aes(): mapea una variable -> genera leyenda automática
2 geom_point(aes(color = continent)) # color según el continente
3
4 # FUERA de aes(): valor fijo para todos los puntos -> no genera leyenda
5 geom_point(color = "steelblue")    # todos los puntos azules
```

Error clásico: `aes(color = "blue")`. En lugar de colorear en azul, R trata "blue" como una categoría de una sola observación y asigna el primer color de la paleta. Los valores fijos van fuera de `aes()`.

geom_histogram(): introducción

El histograma divide el rango de una variable en intervalos (bins) y cuenta cuántas observaciones caen en cada uno. Es el gráfico más directo para explorar la distribución de una variable continua.

```
1 ggplot(gapminder_2007, aes(x = gdpPercap)) +  
2   geom_histogram()
```




Por defecto, ggplot2 usa 30 bins y muestra el mensaje `'stat_bin()' using 'bins = 30'`. Pick better value with `'binwidth'`. No es un error: es un recordatorio.

geom_histogram(): bins y binwidth


El número y ancho de los bins cambia drásticamente cómo se percibe la distribución. Es importante elegir un valor informativo: ni tan fino que muestre ruido, ni tan grueso que pierda estructura.

```
1 # bins: número total de intervalos
2 ggplot(gapminder_2007, aes(x = gdpPercap)) +
3   geom_histogram(bins = 10)
```




geom_histogram(): bins y binwidth

```
1 ggplot(gapminder_2007, aes(x = gdpPercap)) +  
2   geom_histogram(bins = 50)
```



geom_histogram(): bins y binwidth

```
1 # binwidth: ancho de cada intervalo en las unidades de la variable
2 ggplot(gapminder_2007, aes(x = gdpPercap)) +
3   geom_histogram(binwidth = 5000) # intervalos de USD 5.000
```




bins y binwidth son equivalentes: especificar uno determina el otro. **binwidth** suele ser más interpretable porque se expresa en las unidades de la variable: **binwidth = 5000** significa intervalos de USD 5.000.

geom_histogram(): fill, color y alpha

fill controla el **interior** de las barras; **color** controla el **borde**. **alpha** ajusta la transparencia (de **0** completamente invisible a **1** completamente sólido).

```
1 ggplot(gapminder_2007, aes(x = gdpPercap)) +  
2   geom_histogram(  
3     binwidth = 5000,  
4     fill      = "steelblue",  
5     color     = "white",  
6     alpha     = 0.8  
7   )
```




`fill = "steelblue"` y `color = "white"` van fuera de `aes()` porque son valores fijos, no variables. Si se quisiera colorear cada barra según el continente, ahí sí irían dentro de `aes()`.

geom_density()

`geom_density()` estima una función de densidad de probabilidad continua a partir de los datos. Es una versión suavizada del histograma que elimina la arbitrariedad de los bins.

```
1 ggplot(gapminder_2007, aes(x = gdpPerCap)) +  
2   geom_density(fill = "steelblue", alpha = 0.5)
```




El parámetro `adjust` controla el suavizado: `adjust = 0.5` produce una curva más irregular (más detalle), `adjust = 2` produce una curva más suave (menos detalle). El default es `adjust = 1`.

Distribuciones por grupo


Asignar una variable discreta a `fill` dentro de `aes()` genera una distribución separada por grupo. El parámetro `alpha` permite ver el solapamiento entre grupos.

```
1 # Densidades superpuestas por continente
2 ggplot(gapminder_2007, aes(x = gdpPercap, fill = continent)) +
3   geom_density(alpha = 0.4)
```



Distribuciones por grupo

```
1 # Histogramas superpuestos: position = "identity" evita el apilado
2 ggplot(gapminder_2007, aes(x = gdpPercap, fill = continent)) +
3   geom_histogram(binwidth = 5000, alpha = 0.5,
4                 position = "identity")
```




En los histogramas, `position = "identity"` hace que las barras se superpongan. Sin él, el default `position = "stack"` apila cada grupo sobre el anterior, lo que dificulta comparar las distribuciones.

El diagrama de caja (boxplot) resume la distribución con cinco estadísticos y señala los valores atípicos. Es compacto y permite comparar grupos de un vistazo.

Elemento	Qué representa
Línea central	mediana (Q2: percentil 50)
Borde inferior de la caja	primer cuartil (Q1: percentil 25)
Borde superior de la caja	tercer cuartil (Q3: percentil 75)
Altura de la caja	rango intercuartílico (RIC = $Q3 - Q1$)
Bigotes	se extienden hasta $1,5 \times \text{RIC}$ desde la caja
Puntos sueltos	outliers: valores más allá de los bigotes


```
1 # Un único boxplot (sin grupos): x queda vacío
2 ggplot(gapminder_2007, aes(y = gdpPercap)) +
3   geom_boxplot()
```



geom_boxplot(): comparación entre grupos

Mapear una variable discreta al eje x genera un boxplot por grupo: es la forma más directa de comparar distribuciones entre categorías.

```
1 ggplot(gapminder_2007, aes(x = continent, y = gdpPercap)) +  
2   geom_boxplot(fill = "steelblue", alpha = 0.7)
```




Si se usa `fill = continent` dentro de `aes()`, cada continente recibe un color distinto y ggplot2 agrega una leyenda automáticamente. Con un valor fijo (`fill = "steelblue"`), todas las cajas tienen el mismo color y no hay leyenda.

Combinar capas: geom_jitter()

El boxplot oculta cuántas observaciones hay y cómo se distribuyen dentro de los cuartiles. Superponerle `geom_jitter()` muestra los puntos individuales con dispersión aleatoria para evitar el solapamiento.


```
1 ggplot(gapminder_2007, aes(x = continent, y = gdpPercap)) +  
2   geom_boxplot(fill = "steelblue", alpha = 0.4,  
3     outlier.shape = NA) +      # oculta outliers del boxplot  
4   geom_jitter(width = 0.2, alpha = 0.6, color = "gray30")
```



geom_violin()


`geom_violin()` combina lo mejor del boxplot (comparación entre grupos) y la densidad (forma de la distribución). El ancho en cada punto es proporcional a la cantidad de observaciones.

```
1 # Violín solo
2 ggplot(gapminder_2007, aes(x = continent, y = gdpPercap)) +
3   geom_violin(fill = "steelblue", alpha = 0.5)
```



geom_violin()

```
1 # Violín + boxplot anidado: combinación muy usada en publicaciones
2 ggplot(gapminder_2007, aes(x = continent, y = gdpPercap)) +
3   geom_violin(fill = "steelblue", alpha = 0.5) +
4   geom_boxplot(width = 0.1, fill = "white")
```




La combinación violín + boxplot anidado muestra la forma de la distribución (violín) y los estadísticos resumen (boxplot). El boxplot anidado tiene sentido cuando hay suficientes observaciones por grupo.

labs(): títulos y etiquetas

`labs()` controla todos los textos del gráfico. Un gráfico sin etiquetas claras es incompleto: el lector no debería tener que adivinar qué está viendo.

```
1 ggplot(gapminder_2007, aes(x = continent, y = gdpPercap, fill = continent)) +  
2   geom_boxplot(alpha = 0.7) +  
3   labs(  
4     title       = "Distribución del PBI per cápita por continente (2007)",  
5     subtitle    = "142 países · dólares internacionales del año 2007",  
6     x           = "Continente",  
7     y           = "PBI per cápita (USD)",  
8     fill        = "Continente",  
9     caption     = "Fuente: Gapminder"  
10  )
```




Los temas controlan el estilo visual del gráfico: fondo, grillas, tipografía, márgenes. `ggplot2` incluye varios temas predefinidos que mejoran notablemente la presentación por defecto.

Tema	Aspecto
<code>theme_gray()</code>	default: fondo gris con grillas blancas
<code>theme_bw()</code>	fondo blanco, borde negro, grillas grises
<code>theme_minimal()</code>	mínimo: sin borde, grillas suaves
<code>theme_classic()</code>	ejes sin grillas; estilo de publicación académica
<code>theme_light()</code>	variante clara de <code>theme_bw()</code>
<code>theme_void()</code>	sin ejes ni fondo; útil para mapas

```

1 ggplot(gapminder_2007, aes(x = continent, y = gdpPercap)) +
2   geom_boxplot(fill = "steelblue", alpha = 0.7) +
3   labs(title = "PBI per cápita por continente (2007)",
4         x = "Continente", y = "PBI per cápita (USD)") +
5   theme_minimal()

```



Usando el dataset `gapminder` (completo, todos los años):

1. Graficá la distribución de la esperanza de vida (`lifeExp`) con un histograma. Probá al menos tres valores distintos de `bins`.
2. Repetí el gráfico anterior pero con `geom_density()`. Probá `adjust = 0.5` y `adjust = 2`. ¿Qué diferencia notás?
3. Graficá la distribución de `lifeExp` con densidades separadas por continente. Usá `alpha = 0.4`.
4. Creá un boxplot de `lifeExp` por continente. Luego agregale color con `fill = continent`.
5. Superponele puntos con `geom_jitter()` al boxplot anterior. ¿Qué continente muestra mayor dispersión interna?
6. Graficá la distribución del PBI per cápita (`gdpPercap`) solo para los años 1952 y 2007 en un mismo gráfico de densidad. Usá `fill` para distinguir los años. ¿Qué cambió?
7. Repetí el ejercicio anterior pero con `geom_histogram()`. ¿Qué problema aparece si no usás `position = "identity"`?
8. Usando solo los datos de América (`continent == "Americas"`), hacé un boxplot de `lifeExp` por año. ¿Cómo cambió la distribución?

9. Creá un histograma de `gdpPercap` para 2007. Modificá `fill`, `color` y `alpha` hasta obtener una presentación que te parezca clara.
10. Aplicá los temas `theme_minimal()`, `theme_classic()` y `theme_bw()` a un mismo gráfico. ¿Cuál te parece más apropiado para un informe académico?
11. Tomá el boxplot del ejercicio 4 y completalo con `labs()`: título descriptivo, etiquetas de ejes en español y nota al pie con la fuente (Gapminder).
12. Usando todo el dataset, graficá la distribución de la población (`pop`). ¿Qué forma tiene? ¿Qué observación se puede hacer sobre la mayoría de los países?
13. Elegí dos continentes y compará la distribución del PBI per cápita en 2007 usando los tres tipos de gráfico vistos: densidades superpuestas, histogramas y boxplot. ¿Cuál comunica mejor las diferencias?
14. Usá `geom_violin()` + `geom_boxplot()` anidado para comparar la distribución de `lifeExp` entre los cinco continentes en 2007. Agregá título, etiquetas de ejes y un tema apropiado para presentación.
15. El dataset cubre el período 1952–2007. Creá un gráfico de densidad de `lifeExp` que compare los años 1952, 1977 y 2007. ¿Qué tendencia muestra? Completá el gráfico con `labs()` y `theme_minimal()`.

En el próximo encuentro: `geom_line()` para series de tiempo, `geom_col()` para comparaciones categóricas, `geom_smooth()` para tendencias y `facet_wrap()` para paneles múltiples.

Actividad integradora semanal (se sube al aula)

Integraremos los gráficos de distribución del encuentro con las herramientas de transformación ya conocidas. Trabajaremos con `gapminder` (del paquete `gapminder`) y con el dataset `iris`. Asegurate de tener `tidyverse` y `gapminder` cargados.

1. Filtrá `gapminder` para quedarte con los años **1952** y **2007**. Con esos datos, construí un gráfico de densidad de **lifeExp** usando `fill` para distinguir los dos años (`alpha = 0.4`). Completá con `labs()` –título descriptivo, ejes en español y fuente Gapminder– y `theme_bw()`. ¿Qué cambió en la distribución de la esperanza de vida entre ambos años?
2. Con `gapminder` filtrado al año **2007**, construí un violin plot de **lifeExp** por continente (`fill = continent`) con un boxplot anidado dentro (`width = 0.1`, `fill = "white"`). Completá con `labs()` y `theme_minimal()`. ¿Qué continente muestra mayor dispersión interna en la esperanza de vida?
3. El dataset `iris` tiene cuatro variables de medición en columnas separadas: **Sepal.Length**, **Sepal.Width**, **Petal.Length** y **Petal.Width**, lo que lo deja en formato ancho. Para graficar la distribución de las cuatro medidas en un único boxplot, transformalo a formato largo con `pivot_longer()`: excluí **Species** de la selección y nombrá las nuevas columnas **"medida"** y **"valor"**. Con el resultado, construí un boxplot con **medida** en x, **valor** en y y `fill = medida`. ¿Qué variable tiene el mayor rango intercuartílico?

4. Retomá el reshape del ejercicio anterior. Esta vez usá `fill = Species` en lugar de `medida` para comparar las tres especies dentro de cada tipo de medición (`alpha = 0.7`). Completá con `labs()` y `theme_bw()`. ¿En cuál de las cuatro medidas se diferencian más las tres especies entre sí?
5. Construí un único pipeline que parta de `gapminder`, filtre los países de América y produzca un histograma de `gdpPercap` con `binwidth = 2000`, `fill` fijo en `"steelblue"`, `color = "white"` y `alpha = 0.8`. Completá con `labs()` descriptivos y `theme_classic()`. ¿La distribución del PBI per cápita en América es simétrica o asimétrica? ¿A qué se debe esa forma?