R: limpieza, manipulación y exploración de datos

9no encuentro: Visualización de datos II

Jonatán Perren

28 de marzo de 2026

Agenda

- **Series de tiempo:** `geom_line()` y `geom_point()`
- **Comparación categórica:** `geom_col()` y `geom_bar()`
- **Dispersión y tendencia:** `geom_point()` con `geom_smooth()`
- **Estéticas:** `size`, `alpha`, `color`
- **Pequeños múltiples:** `facet_*()`

Paquetes y datos

```r
library(tidyverse)
library(gapminder)

gapminder_2007 <- gapminder |> filter(year == 2007)

# Países seleccionados para ejemplos de series de tiempo
paises <- c("Argentina", "Brazil", "Mexico", "Chile")
gapminder_paises <- gapminder |> filter(country %in% paises)
```

`geom_line()`: series de tiempo

`geom_line()` conecta las observaciones en el orden del eje `x`. Es la geometría natural para representar la evolución de una variable a lo largo del tiempo.

```
# Evolución del PBI per cápita de Argentina
gapminder ⊳
  filter(country == "Argentina") ⊳
  ggplot(aes(x = year, y = gdpPercap)) +
  geom_line()
```

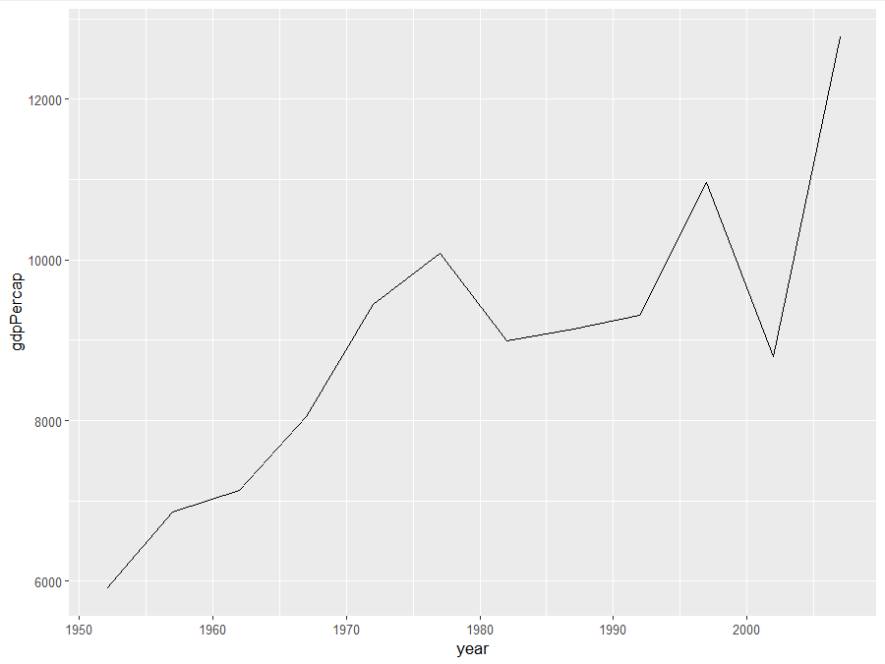

`geom_line()` asume que las observaciones están ordenadas por `x`. Si los datos no están en orden, la línea zigzaguea de forma incorrecta. Se puede asegurar el orden con `arrange(year)` antes de pasar los datos a `ggplot()`.

Múltiples series: `color` y `group`

Para trazar una línea por grupo, se mapea la variable de grupo a **`color`** dentro de **`aes()`**. ggplot2 genera una línea por grupo y agrega la leyenda automáticamente.

```
ggplot(gapminder_paises,
       aes(x = year, y = gdpPercap, color = country)) +
  geom_line()
```

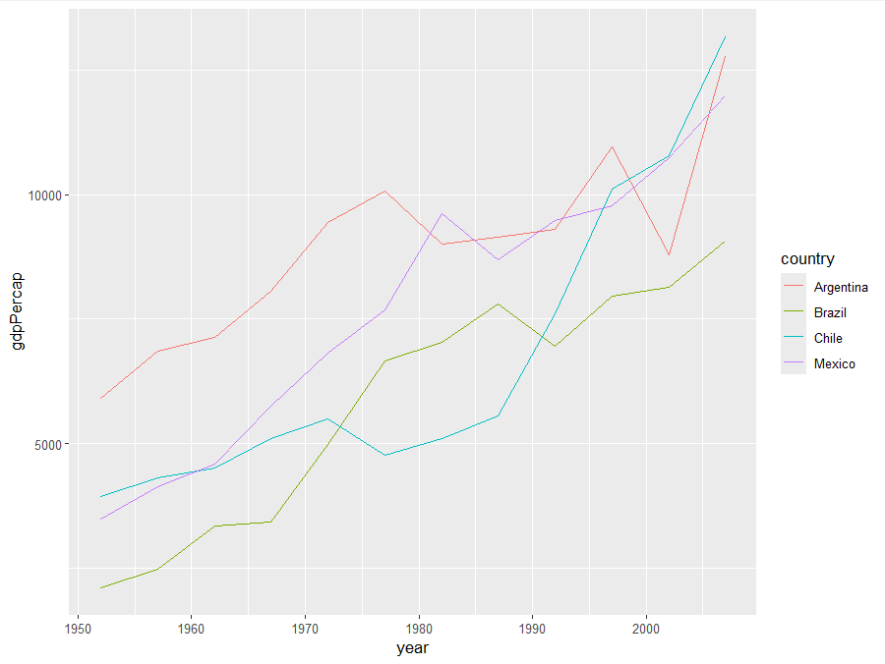

Si no se especifica **`group`** ni **`color`** con una variable discreta, todas las observaciones de distintos países se conectan en una sola línea zigzagueante. Es el error más frecuente al usar **`geom_line()`** con datos de panel.

`group` controla el agrupado sin cambiar el color. **`color`** agrupa **y** colorea al mismo tiempo. Si ya se usa **`color`**, no hace falta especificar **`group`** por separado.

Combinar `geom_line()` y `geom_point()`

Superponer **`geom_point()`** sobre **`geom_line()`** marca las observaciones individuales. Útil cuando los datos son escasos o cuando los intervalos de tiempo son irregulares.

```
ggplot(gapminder_paises,
       aes(x = year, y = gdpPercap, color = country)) +
  geom_line() +
  geom_point(size = 2)
```

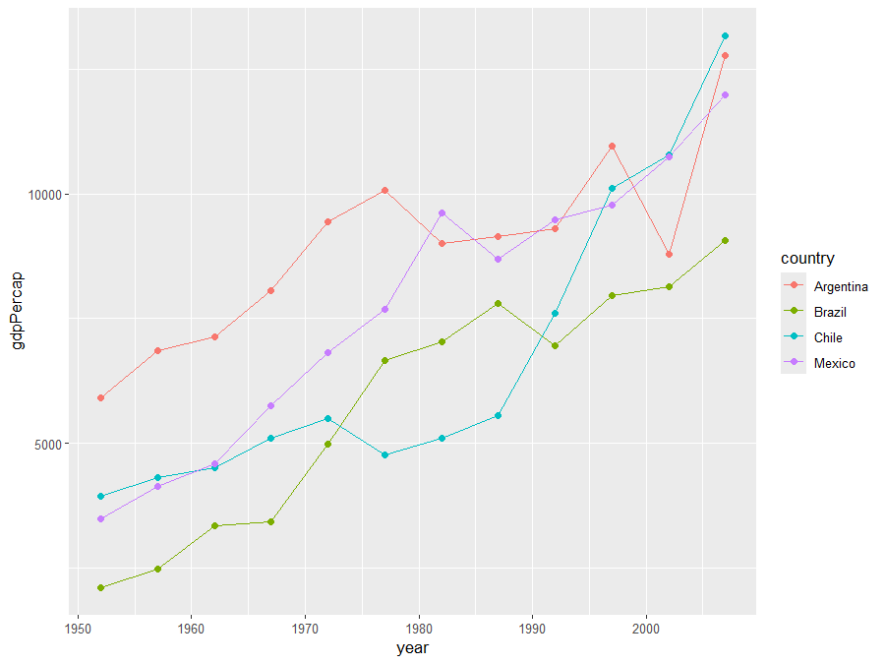

Las capas se dibujan en el orden en que se agregan. **`geom_point()`** va después de **`geom_line()`** para que los puntos queden encima de las líneas.

geom_col(): barras proporcionales al valor

geom_col() dibuja barras cuya altura es el **valor de la variable** mapeada al eje **y**. Se usa cuando los datos ya están resumidos.

```
# PBI per cápita promedio por continente en 2007
gdp_continente <- gapminder_2007 |>
  group_by(continent) |>
  summarise(gdp_medio = mean(gdpPercap))

ggplot(gdp_continente, aes(x = continent, y = gdp_medio)) +
  geom_col(fill = "steelblue")
```

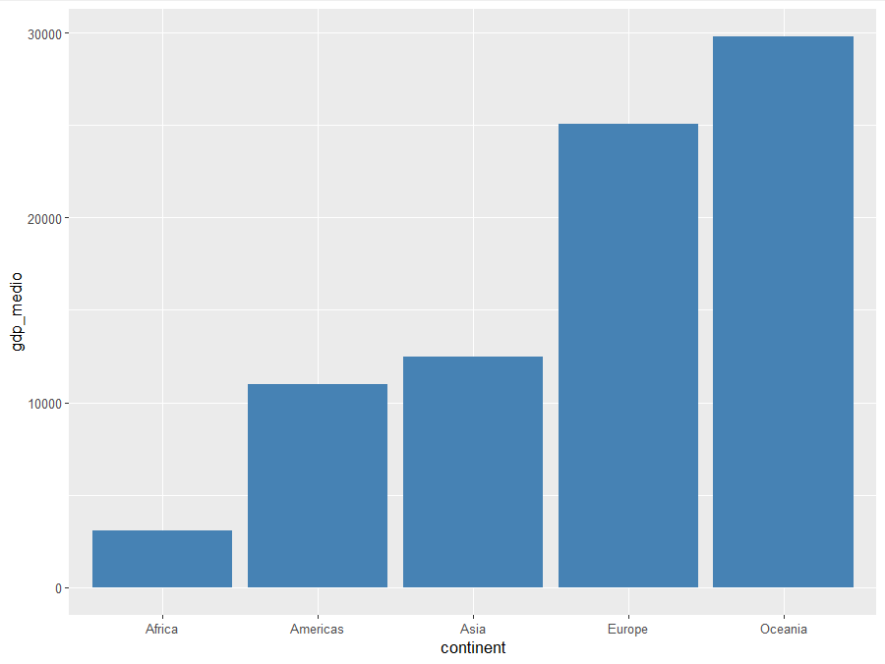

`geom_col()` es equivalente a `geom_bar(stat = "identity")`. En la práctica, `geom_col()` es preferible cuando los datos ya vienen resumidos: el nombre lo deja explícito.

`geom_bar()`: barras de conteo

`geom_bar()` cuenta el número de observaciones por categoría y dibuja la barra. **No requiere una variable en el eje y**: el conteo lo calcula automáticamente.

```
# Cuántos países hay por continente en 2007
ggplot(gapminder_2007, aes(x = continent)) +
  geom_bar(fill = "steelblue")
```

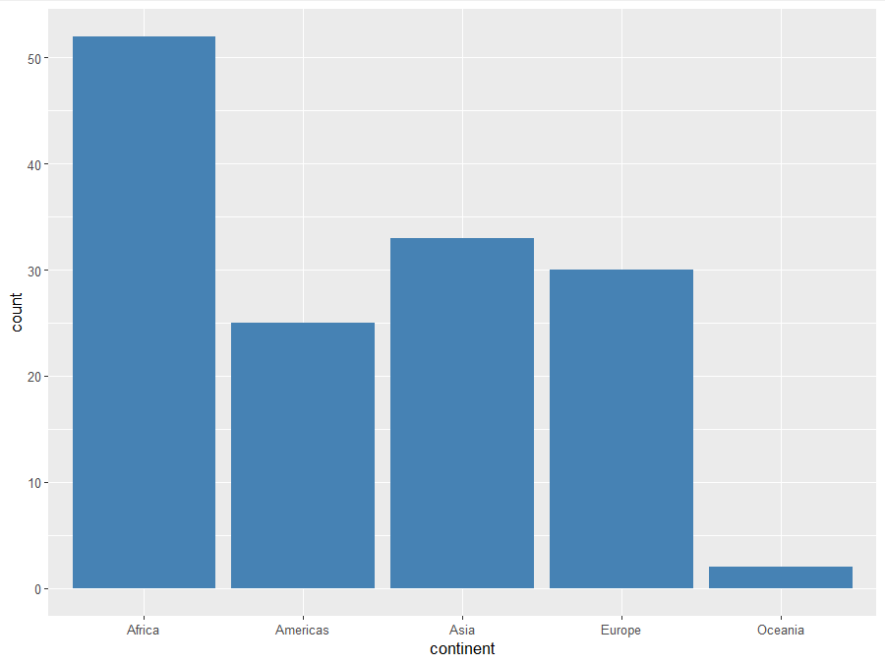

Función	Eje y	Cuándo usarla
`geom_bar()`	conteo automático	datos sin resumir: cuenta filas por categoría
`geom_col()`	valor de la variable	datos ya resumidos: usa el valor directamente

Barras horizontales y ordenamiento

Invertir los ejes mejora la legibilidad cuando las etiquetas son largas. La forma más limpia es mapear la variable categórica al eje y.

```r
# Barras horizontales: continent en eje y
ggplot(gdp_continente,
       aes(x = gdp_medio, y = continent)) +
  geom_col(fill = "steelblue")
```

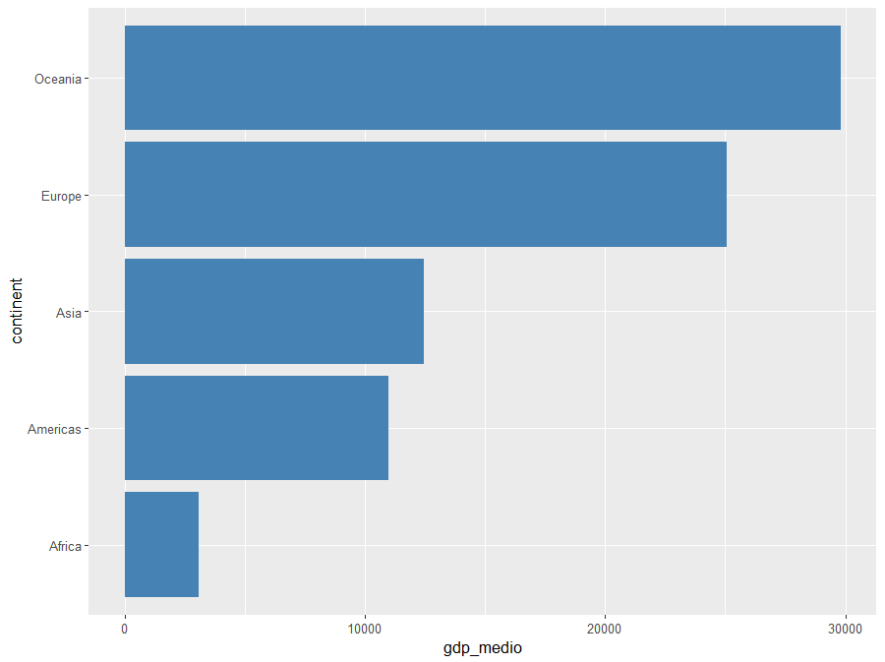

Barras horizontales y ordenamiento

```r
# Ordenar por valor: reorder() reordena el factor según otra variable
ggplot(gdp_continente,
       aes(x = gdp_medio,
           y = reorder(continent, gdp_medio))) +
  geom_col(fill = "steelblue") +
  labs(y = "Continente")
```

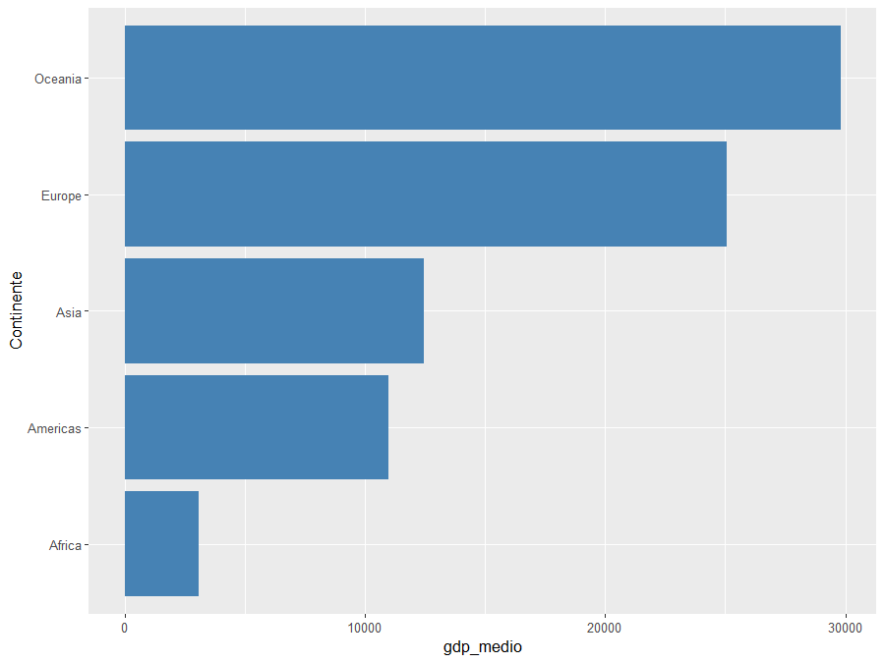

`reorder(continent, gdp_medio)` reordena los niveles del factor `continent` según el valor de `gdp_medio`. Sin esto, las barras se ordenan alfabéticamente, lo que dificulta la comparación visual.

`geom_smooth()`: curva de tendencia

`geom_smooth()` superpone una curva de tendencia sobre el scatterplot. Es útil para visualizar la relación entre dos variables continuas sin imponer una forma funcional.

```
# Suavizado local (por defecto con menos de 1000 observaciones)
ggplot(gapminder_2007, aes(x = gdpPercap, y = lifeExp)) +
  geom_point(alpha = 0.6) +
  geom_smooth()
```

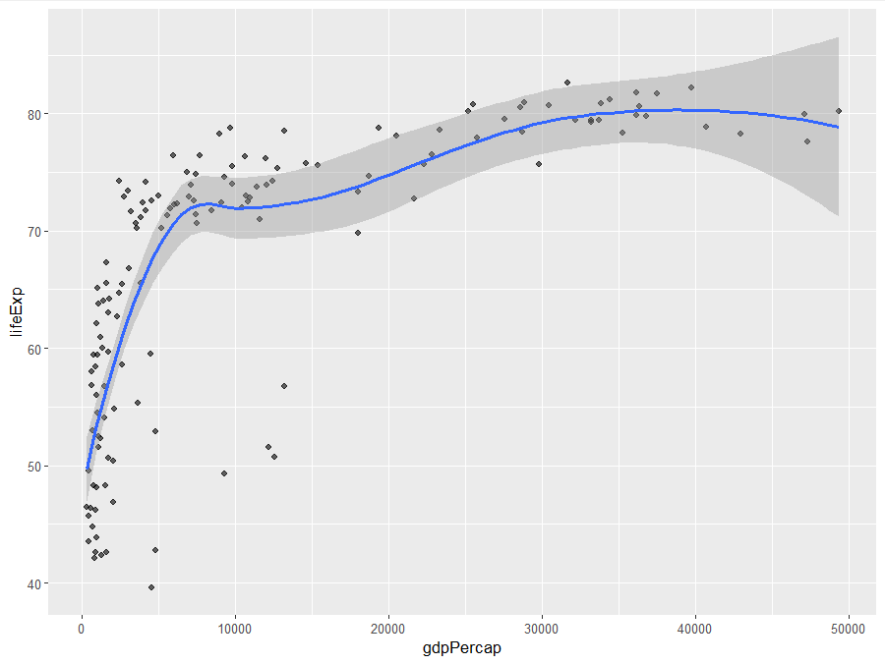

geom_smooth(): curva de tendencia

```r
# Regresión lineal: method = "lm"
ggplot(gapminder_2007, aes(x = gdpPercap, y = lifeExp)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE, color = "firebrick")
```

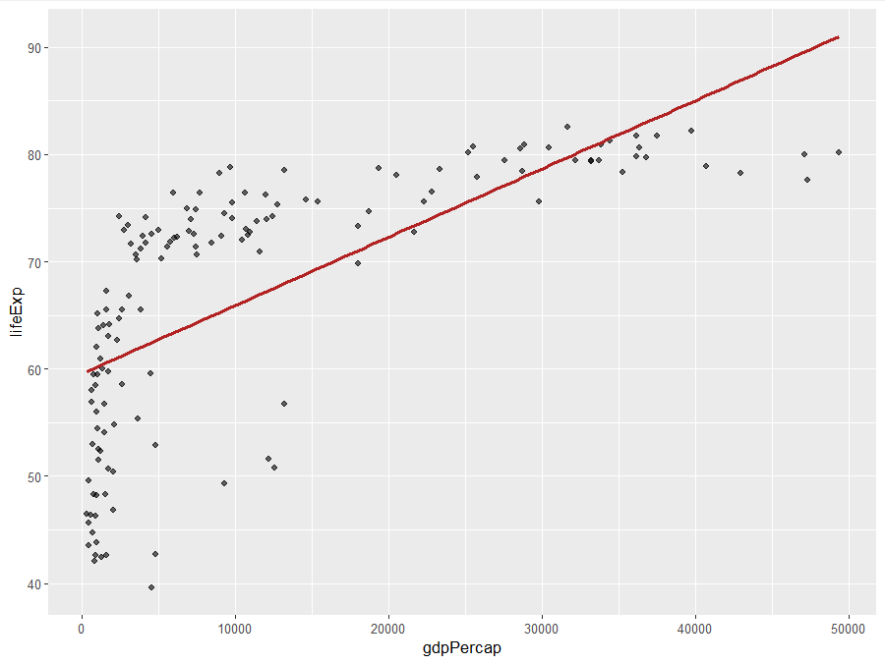

Por defecto se usa `method = "loess"` (suavizado local). La banda gris es el intervalo de confianza al 95 %; se desactiva con `se = FALSE`. Con `method = "lm"` se ajusta una recta de regresión lineal.

Escala logarítmica: `scale_x_log10()`

La relación entre PBI per cápita y esperanza de vida no es lineal: es aproximadamente lineal en escala logarítmica. `scale_x_log10()` transforma el eje sin modificar los datos.

```
ggplot(gapminder_2007,
       aes(x = gdpPercap, y = lifeExp, color = continent)) +
  geom_point(alpha = 0.7) +
  geom_smooth(method = "lm", se = FALSE) +
  scale_x_log10() +
  labs(
    title   = "PBI per cápita y esperanza de vida (2007)",
    x       = "PBI per cápita (USD, escala log)",
    y       = "Esperanza de vida (años)",
    color   = "Continente",
    caption = "Fuente: Gapminder"
  )
```

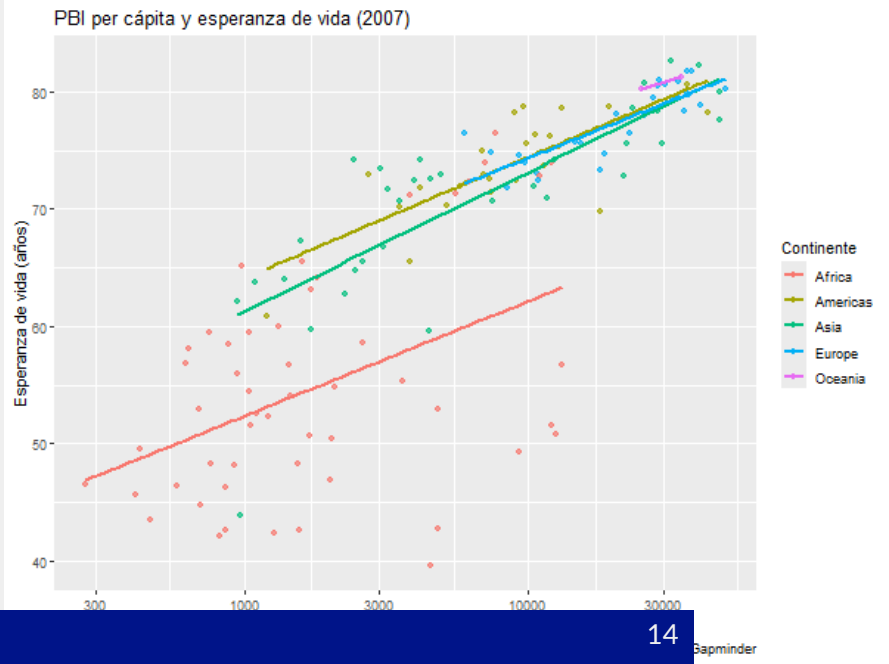

El `geom_smooth()` hereda las estéticas globales: como `color = continent` está en `aes()`, calcula una recta por continente. Para una recta global, mover `color` al `aes()` local de `geom_point()`.

Gráfico de burbujas: `size` como estética

Mapear una variable continua a `size` produce un **gráfico de burbujas**. Combinado con `color`, permite representar cuatro variables simultáneamente.

```
ggplot(gapminder_2007,
       aes(x = gdpPercap, y = lifeExp, size = pop, color = continent)) +
  geom_point(alpha = 0.6) +
  scale_x_log10() +
  scale_size_area(max_size = 15) +
  labs(
    title  = "Riqueza, salud y población (2007)",
    x      = "PBI per cápita (USD, escala log)",
    y      = "Esperanza de vida (años)",
    size   = "Población",
    color = "Continente"
  )
```

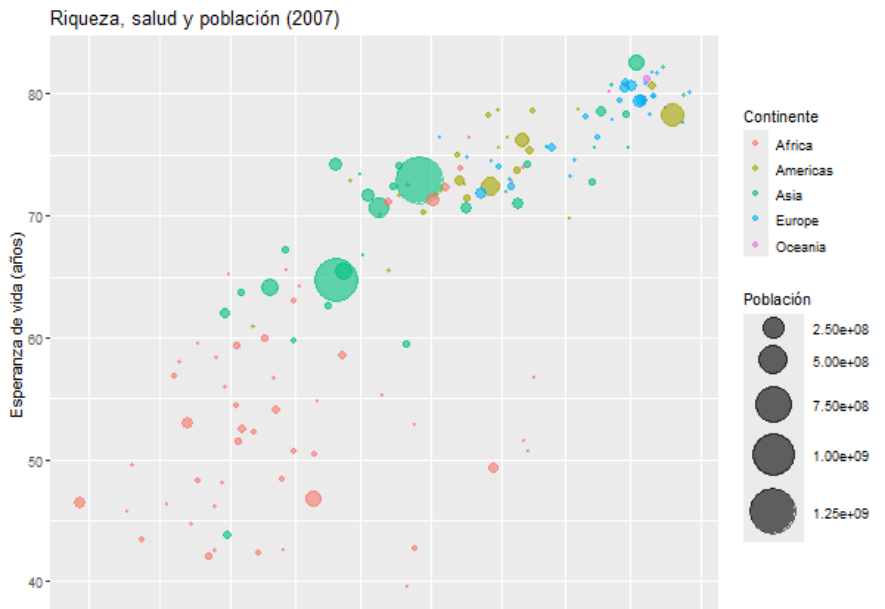

`scale_size_area()` hace que el **área** del punto sea proporcional al valor, no el radio. Esto es perceptualmente correcto: si el radio fuera proporcional, los puntos grandes parecerían desproporcionadamente más grandes.

`facet_wrap()`: pequeños múltiples

`facet_wrap()` divide el gráfico en paneles, uno por cada nivel de una variable. Permite comparar la misma relación entre grupos sin solapar la información en un único gráfico.

```
# Un panel por continente
ggplot(gapminder_2007,
       aes(x = gdpPercap, y = lifeExp)) +
  geom_point(alpha = 0.6) +
  facet_wrap(~ continent)
```

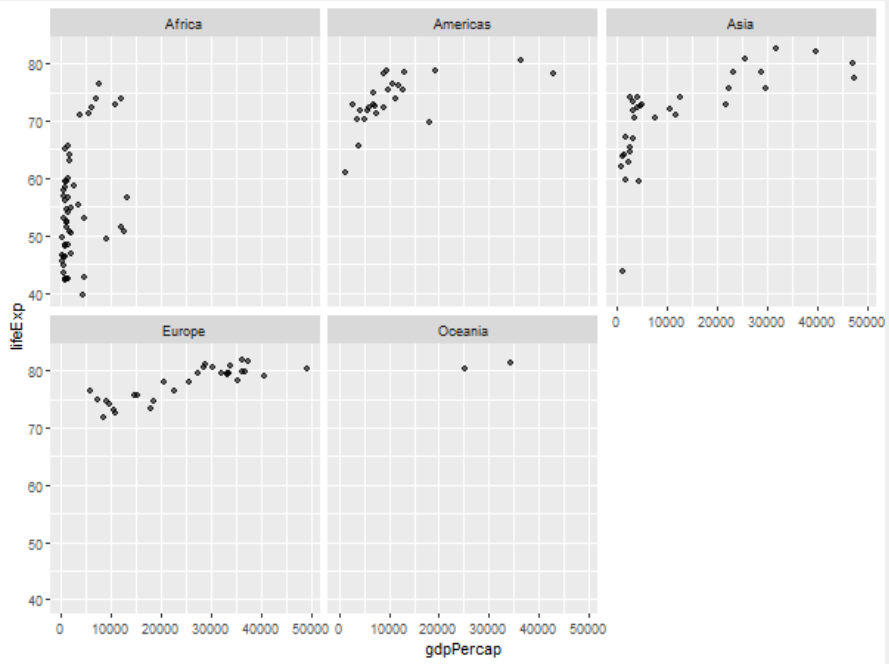

`facet_wrap()`: pequeños múltiples

```
# Controlar columnas y permitir escalas independientes
ggplot(gapminder_2007,
       aes(x = gdpPercap, y = lifeExp)) +
  geom_point(alpha = 0.6) +
  facet_wrap(~ continent, ncol = 2, scales = "free_x")
```

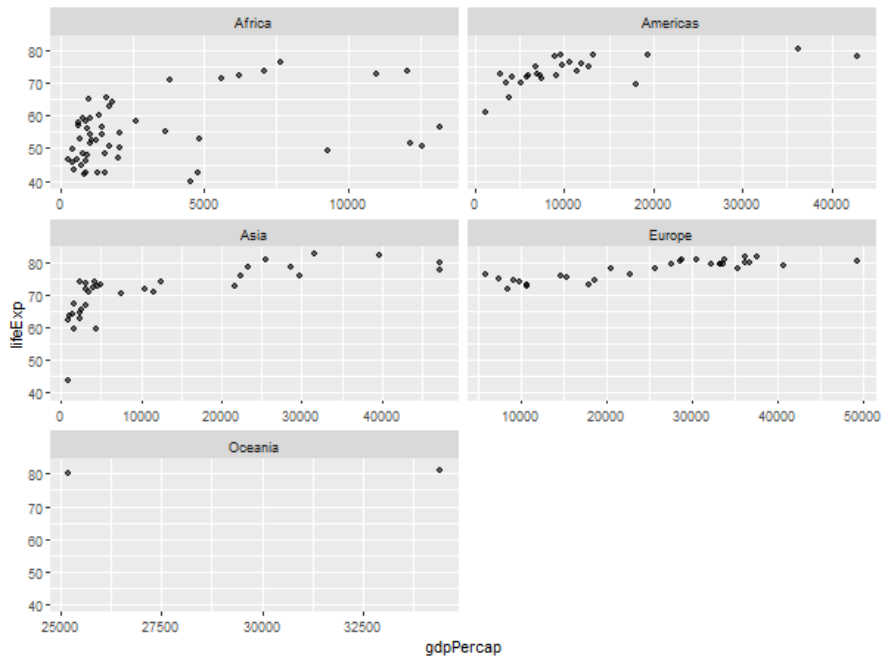

Por defecto, todos los paneles comparten la misma escala en ambos ejes (`scales = "fixed"`). Con `scales = "free"` cada panel ajusta su escala individualmente; con `scales = "free_x"` solo el eje x varía. Escalas libres muestran mejor la variación interna pero dificultan la comparación entre paneles.

`facet_grid()`: cuadrícula de dos variables

`facet_grid()` organiza los paneles en una cuadrícula bidimensional: una variable define las filas y otra las columnas.

```
# Filas: year, columnas: continent
gapminder ⊳
  filter(year %in% c(1952, 1977, 2007)) ⊳
  ggplot(aes(x = gdpPercap, y = lifeExp)) +
  geom_point(alpha = 0.5) +
  facet_grid(year ~ continent) +
  scale_x_log10()
```

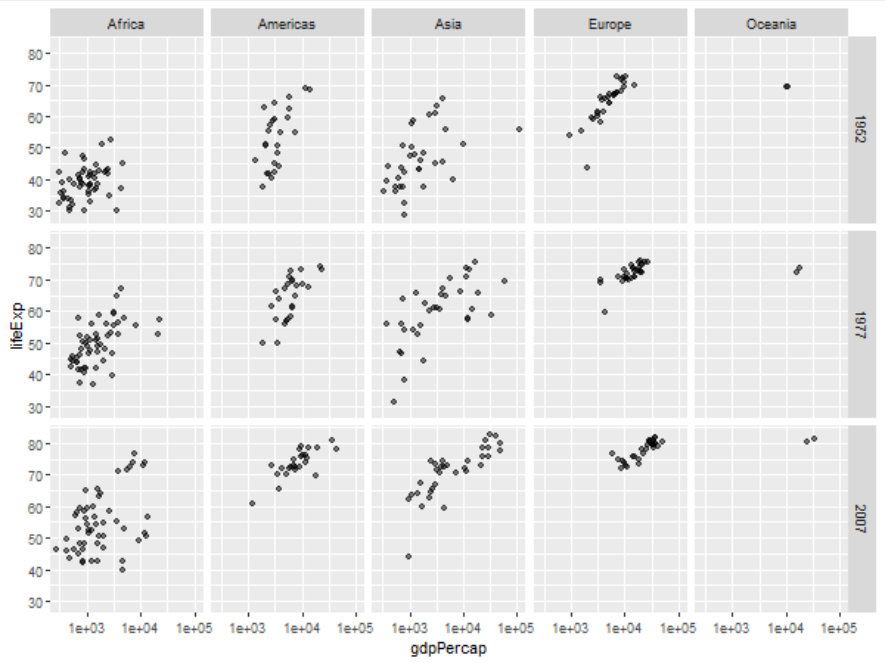

Sintaxis	Resultado	Cuándo usarla
`facet_wrap(~ var)`	múltiples paneles en filas/columnas	una sola variable de facetado
`facet_grid(f ~ c)`	cuadrícula: filas = f, columnas = c	cruzar dos variables
`facet_grid(. ~ c)`	solo columnas	una variable, comparar en horizontal
`facet_grid(f ~ .)`	solo filas	una variable, comparar en vertical

Ejercicios

Usando el dataset `gapminder`:

1. Graficá la evolución de la esperanza de vida (`lifeExp`) entre 1952 y 2007 para los cinco países con mayor población en 2007. Usá `geom_line()` + `geom_point()`, con una línea por país coloreada por `country`.
2. Calculá el PBI per cápita promedio por continente para 1952 y 2007. Graficá el resultado con `geom_col()` en barras horizontales ordenadas de mayor a menor, usando `facet_wrap()` para separar los dos años.
3. Reproducí el gráfico de burbujas clásico de Gapminder para el año 2007: PBI per cápita (eje `x`, escala log) vs. esperanza de vida (eje `y`), tamaño proporcional a la población y color por continente. Agregá etiquetas con `labs()`.
4. Usando `facet_grid(continent ~ .)`, graficá la distribución del PBI per cápita con `geom_density()` para cada continente en 2007. ¿Qué diferencias observás en la forma de cada distribución?