

R: limpieza, manipulación y exploración de datos

9no encuentro: Visualización de datos II

Jonatán Perren

3 de junio de 2026

- Series de tiempo: `geom_line()` y `geom_point()`
- Comparación categórica: `geom_col()` y `geom_bar()`
- Dispersión y tendencia: `geom_point()` con `geom_smooth()`
- Estéticas: `size`, `alpha`, `color`
- Pequeños múltiples: `facet_*()`


Paquetes y datos

```
1 library(tidyverse)
2 library(gapminder)
3
4 gapminder_2007 <- gapminder > filter(year == 2007)
5
6 # Países seleccionados para ejemplos de series de tiempo
7 paises <- c("Argentina", "Brazil", "Mexico", "Chile")
8 gapminder_paises <- gapminder > filter(country %in% paises)
```

geom_line(): series de tiempo

`geom_line()` conecta las observaciones en el orden del eje x. Es la geometría natural para representar la evolución de una variable a lo largo del tiempo.

```
1 # Evolución del PBI per cápita de Argentina
2 gapminder ►
3 filter(country == "Argentina") ►
4 ggplot(aes(x = year, y = gdpPercap)) +
5 geom_line()
```




`geom_line()` asume que las observaciones están ordenadas por x. Si los datos no están en orden, la línea zigzaguea de forma incorrecta. Se puede asegurar el orden con `arrange(year)` antes de pasar los datos a `ggplot()`.


Múltiples series: color y group

Para trazar una línea por grupo, se mapea la variable de grupo a `color` dentro de `aes()`. `ggplot2` genera una línea por grupo y agrega la leyenda automáticamente.

```
1 ggplot(gapminder_paises,  
2       aes(x = year, y = gdpPercap, color = country)) +  
3       geom_line()
```



Si no se especifica **group** ni **color** con una variable discreta, todas las observaciones de distintos países se conectan en una sola línea zigzagueante. Es el error más frecuente al usar `geom_line()` con datos de panel.




group controla el agrupado sin cambiar el color. **color** agrupa y colorea al mismo tiempo. Si ya se usa **color**, no hace falta especificar **group** por separado.

Combinar `geom_line()` y `geom_point()`

Superponer `geom_point()` sobre `geom_line()` marca las observaciones individuales. Útil cuando los datos son escasos o cuando los intervalos de tiempo son irregulares.

```
1 ggplot(gapminder_paises,  
2       aes(x = year, y = gdpPerCap, color = country)) +  
3   geom_line() +  
4   geom_point(size = 2)
```




Las capas se dibujan en el orden en que se agregan. `geom_point()` va después de `geom_line()` para que los puntos queden encima de las líneas.

geom_col(): barras proporcionales al valor

`geom_col()` dibuja barras cuya altura es el valor de la variable mapeada al eje y. Se usa cuando los datos ya están resumidos.

```
1 # PBI per cápita promedio por continente en 2007
2 gdp_continente <- gapminder_2007 %>%
3   group_by(continent) %>%
4   summarise(gdp_medio = mean(gdpPercap))
5
6 ggplot(gdp_continente, aes(x = continent, y = gdp_medio)) +
7   geom_col(fill = "steelblue")
```




`geom_col()` es equivalente a `geom_bar(stat = "identity")`. En la práctica, `geom_col()` es preferible cuando los datos ya vienen resumidos: el nombre lo deja explícito.

geom_bar(): barras de conteo

`geom_bar()` cuenta el número de observaciones por categoría y dibuja la barra. No requiere una variable en el eje y: el conteo lo calcula automáticamente.

```
1 # Cuántos países hay por continente en 2007
2 ggplot(gapminder_2007, aes(x = continent)) +
3   geom_bar(fill = "steelblue")
```




Función	Eje y	Cuándo usarla
<code>geom_bar()</code>	conteo automático	datos sin resumir: cuenta filas por categoría
<code>geom_col()</code>	valor de la variable	datos ya resumidos: usa el valor directamente

Barras horizontales y ordenamiento


Invertir los ejes mejora la legibilidad cuando las etiquetas son largas. La forma más limpia es mapear la variable categórica al eje y.

```
1 # Barras horizontales: continent en eje y
2 ggplot(gdp_continente,
3       aes(x = gdp_medio, y = continent)) +
4       geom_col(fill = "steelblue")
```



Barras horizontales y ordenamiento

```
1 # Ordenar por valor: reorder() reordena el factor según otra variable
2 ggplot(gdp_continente,
3       aes(x = gdp_medio,
4           y = reorder(continent, gdp_medio))) +
5   geom_col(fill = "steelblue") +
6   labs(y = "Continente")
```




`reorder(continent, gdp_medio)` reordena los niveles del factor `continent` según el valor de `gdp_medio`. Sin esto, las barras se ordenan alfabéticamente, lo que dificulta la comparación visual.

geom_smooth(): curva de tendencia


`geom_smooth()` superpone una curva de tendencia sobre el scatterplot. Es útil para visualizar la relación entre dos variables continuas sin imponer una forma funcional.

```
1 # Suavizado local (por defecto con menos de 1000 observaciones)
2 ggplot(gapminder_2007, aes(x = gdpPercap, y = lifeExp)) +
3   geom_point(alpha = 0.6) +
4   geom_smooth()
```



geom_smooth(): curva de tendencia

```
1 # Regresión lineal: method = "lm"  
2 ggplot(gapminder_2007, aes(x = gdpPercap, y = lifeExp)) +  
3   geom_point(alpha = 0.6) +  
4   geom_smooth(method = "lm", se = FALSE, color = "firebrick")
```




Por defecto se usa `method = "loess"` (suavizado local). La banda gris es el intervalo de confianza al 95 %; se desactiva con `se = FALSE`. Con `method = "lm"` se ajusta una recta de regresión lineal.

Escala logarítmica: `scale_x_log10()`

La relación entre PBI per cápita y esperanza de vida no es lineal: es aproximadamente lineal en escala logarítmica. `scale_x_log10()` transforma el eje sin modificar los datos.

```
1 ggplot(gapminder_2007,  
2       aes(x = gdpPercap, y = lifeExp, color = continent)) +  
3   geom_point(alpha = 0.7) +  
4   geom_smooth(method = "lm", se = FALSE) +  
5   scale_x_log10() +  
6   labs(  
7     title = "PBI per cápita y esperanza de vida (2007)",  
8     x     = "PBI per cápita (USD, escala log)",  
9     y     = "Esperanza de vida (años)",  
10    color = "Continente",  
11    caption = "Fuente: Gapminder"  
12  )
```




El `geom_smooth()` hereda las estéticas globales: como `color = continent` está en `aes()`, calcula una recta por continente. Para una recta global, mover `color` al `aes()` local de `geom_point()`.

Gráfico de burbujas: size como estética

Mapear una variable continua a **size** produce un **gráfico de burbujas**. Combinado con **color**, permite representar cuatro variables simultáneamente.

```
1 ggplot(gapminder_2007,  
2       aes(x = gdpPercap, y = lifeExp, size = pop, color = continent)) +  
3   geom_point(alpha = 0.6) +  
4   scale_x_log10() +  
5   scale_size_area(max_size = 15) +  
6   labs(  
7     title = "Riqueza, salud y población (2007)",  
8     x     = "PBI per cápita (USD, escala log)",  
9     y     = "Esperanza de vida (años)",  
10    size  = "Población",  
11    color = "Continente"  
12  )
```




`scale_size_area()` hace que el **área** del punto sea proporcional al valor, no el radio. Esto es perceptualmente correcto: si el radio fuera proporcional, los puntos grandes parecerían desproporcionadamente más grandes.

facet_wrap(): pequeños múltiples


`facet_wrap()` divide el gráfico en paneles, uno por cada nivel de una variable. Permite comparar la misma relación entre grupos sin solapar la información en un único gráfico.

```
1 # Un panel por continente
2 ggplot(gapminder_2007,
3       aes(x = gdpPercap, y = lifeExp)) +
4   geom_point(alpha = 0.6) +
5   facet_wrap(~ continent)
```



facet_wrap(): pequeños múltiples

```
1 # Controlar columnas y permitir escalas independientes
2 ggplot(gapminder_2007,
3       aes(x = gdpPercap, y = lifeExp)) +
4   geom_point(alpha = 0.6) +
5   facet_wrap(~ continent, ncol = 2, scales = "free_x")
```




Por defecto, todos los paneles comparten la misma escala en ambos ejes (`scales = "fixed"`). Con `scales = "free"` cada panel ajusta su escala individualmente; con `scales = "free_x"` solo el eje x varía. Escalas libres muestran mejor la variación interna pero dificultan la comparación entre paneles.

facet_grid(): cuadrícula de dos variables

`facet_grid()` organiza los paneles en una cuadrícula bidimensional: una variable define las filas y otra las columnas.

```
1 # Filas: year, columnas: continent
2 gapminder ►
3 filter(year %in% c(1952, 1977, 2007)) ►
4 ggplot(aes(x = gdpPercap, y = lifeExp)) +
5 geom_point(alpha = 0.5) +
6 facet_grid(year ~ continent) +
7 scale_x_log10()
```



Sintaxis	Resultado	Cuándo usarla
<code>facet_wrap(~ var)</code>	múltiples paneles en filas/columnas	una sola variable de facetado
<code>facet_grid(f ~ c)</code>	cuadrícula: filas = f, columnas = c	cruzar dos variables
<code>facet_grid(. ~ c)</code>	solo columnas	una variable, comparar en horizontal
<code>facet_grid(f ~ .)</code>	solo filas	una variable, comparar en vertical

Usando el dataset `gapminder`:

1. Graficá la evolución de la esperanza de vida (`lifeExp`) entre 1952 y 2007 para los cinco países con mayor población en 2007. Usá `geom_line()` + `geom_point()`, con una línea por país coloreada por `country`.
2. Calculá el PBI per cápita promedio por continente para 1952 y 2007. Graficá el resultado con `geom_col()` en barras horizontales ordenadas de mayor a menor, usando `facet_wrap()` para separar los dos años.
3. Reproducí el gráfico de burbujas clásico de Gapminder para el año 2007: PBI per cápita (eje x, escala log) vs. esperanza de vida (eje y), tamaño proporcional a la población y color por continente. Agregá etiquetas con `labs()`.
4. Usando `facet_grid(continent ~ .)`, graficá la distribución del PBI per cápita con `geom_density()` para cada continente en 2007. ¿Qué diferencias observás en la forma de cada distribución?

Trabajaremos con `gapminder` (del paquete `gapminder`). Asegurate de tener `tidyverse` y `gapminder` cargados. En estas actividades, las respuestas pueden ser múltiples, por lo que preocúpate por decidir una forma y explicar por qué en un comentario 😊.

1. Elegí cinco países de América Latina y mostrá cómo evolucionó su esperanza de vida entre **1952** y **2007**. Completá el gráfico con título, etiquetas de ejes en español y fuente. ¿Cuál de los cinco mejoró más en ese período?
2. ¿Qué continente tiene la mayor esperanza de vida promedio en **2007** y cuál la menor? Mostrá la comparación con un gráfico de barras ordenado de mayor a menor. ¿Cuántos años los separan?
3. Elegí un país de América. Graficá en simultáneo la evolución de su esperanza de vida (**LifeExp**) y de su PBI per cápita (**gdpPercap**) a lo largo del tiempo, con un panel por variable. ¿Las dos series crecen de manera similar?

4. Para el año 2007, mostrá la relación entre riqueza y esperanza de vida con un panel por continente. Incluí una recta de tendencia en cada panel y usá escala logarítmica en el eje del PBI. ¿En qué continente es más fuerte la asociación?
5. ¿El PBI per cápita promedio de Asia creció de manera lineal entre 1952 y 2007, o se aceleró con el tiempo? Graficá la evolución anual del promedio y sumale una recta de ajuste para visualizarlo.