R: limpieza, manipulación y exploración de datos

Presentación de la materia

Jonatán Perren

20 de marzo de 2026

¿Qué es R?

Un lenguaje de programación
A diferencia del software tradicional donde hacemos clics en menús, en R escribimos instrucciones.

```
resumen <- datos_brutos |>
  filter(anio == 2025) |>
  group_by(categoria) |>
  summarise(promedio = mean(valores))
```

¿Qué es R?

Un entorno estadístico

Fue diseñado específicamente para trabajar con información. Es la herramienta por excelencia para la limpieza, manipulación y exploración de datos.

```r
# Ajustar un modelo de regresión múltiple
modelo <- lm(salario ~ educacion + experiencia,
             data = censo)

# Obtener el resumen estadístico (p-valores, R2, etc.)
summary(modelo)
```

¿Qué es R?

Un puente hacia la práctica
Funciona como un puente instrumental para la aplicación empírica de conceptos teóricos de estadística y economía que ven a lo largo de la licenciatura.

¿Qué es R?

Software libre y de código abierto
Es completamente gratuito, lo que democratiza el acceso, y cuenta con una comunidad global que desarrolla nuevas herramientas constantemente.

¿Por qué R y no Python o Julia?

Enfoque estadístico nativo
A diferencia de Python (lenguaje de propósito general) o Julia (enfocado en alto rendimiento numérico), R fue concebido específicamente para el análisis de datos y la estadística. Eso hace que, en general, su sintaxis sea más amigable para este propósito.
Veamos una comparativa entre las implementaciones de R con otros lenguajes.

```r
library(dplyr) #Con R y dplyr

resumen <- datos_brutos %>%
  filter(anio == 2025) %>%
  group_by(categoria) %>%
  summarise(promedio = mean(valores))
```

```julia
using TidierData, Statistics #Con Julia y TidierData

resumen = @chain datos_brutos begin
    @filter(anio == 2025)
    @group_by(categoria)
    @summarize(promedio = mean(valores))
end
```

```julia
using DataFramesMeta, Statistics #Con Julia y DataFramesMeta

resumen = @chain datos_brutos begin
    @rsubset :anio == 2025
    @groupby :categoria
    @combine :promedio = mean(:valores)
end
```

```julia
using DataFrames, Chain, Statistics #Con Julia, DataFrames y Chain

resumen = @chain datos_brutos begin
    subset(:anio => x -> x .== 2025)
    groupby(:categoria)
    combine(:valores => mean => :promedio)
end
```

```r
library(dplyr) #Con R y dplyr

resumen <- datos_brutos %>
  filter(anio == 2025) %>
  group_by(categoria) %>
  summarise(promedio = mean(valores))
```

```python
import pandas as pd #Con Python y Pandas

datos_filtrados = datos_brutos[datos_brutos["anio"] == 2025]
resumen = datos_filtrados.groupby("categoria")[["valores"]].mean().reset_index()
resumen = resumen.rename(columns = {"valores": "promedio"})
```

```python
import polars as pl #Con Python y Polars

resumen = (
    datos_brutos
    .filter(pl.col("anio") == 2025)
    .group_by("categoria")
    .agg(promedio = pl.col("valores").mean())
)
```

```python
import duckdb #Con Python y duckdb

resumen = duckdb.query("""
    SELECT categoria, AVG(valores) AS promedio
    FROM datos_brutos
    WHERE anio = 2025
    GROUP BY categoria
""").df()
```

Aunque R se ve muy bien en los ejemplos anteriores, ¿sabías que este lenguaje se puede «hablar» en dialectos distintos?

- Dialecto R Base: Es el núcleo original del lenguaje. Es potente y estable, pero a veces su sintaxis puede sentirse un poco arbitraria (aunque no lo es).

```
#Con R y sin librerías
resumen <- datos_brutos |>
  subset(anio == 2025) |>
  aggregate(valores ~ categoria, data = _, FUN = mean)
```

- Dialecto Tidyverse: Es el que vimos recién. Está diseñado específicamente para que el código sea increíblemente legible.

```
library(dplyr) #Con R y dplyr

resumen <- datos_brutos |>
  filter(anio == 2025) |>
  group_by(categoria) |>
  summarise(promedio = mean(valores))
```

La gran diferencia son lo limpias que son las expresiones. Mientras que en otros lenguajes (o en R Base) tienes que explicarle a la computadora cómo hacer las cosas paso a paso, en el dialecto Tidyverse simplemente declaras qué quieres obtener.

¿Por qué R y no Python o Julia?

Puente hacia la Economía

Sirve como puente instrumental para la aplicación empírica de conceptos teóricos de estadística y economía.

```
datos_precios ⊳
  arrange(fecha) ⊳
  mutate(infl_interanual = (ipc / lag(ipc, 12) - 1) * 100)
```

¿Por qué R y no Python o Julia?

Ecosistema Especializado
Cuenta con una comunidad académica inmensa y paquetes desarrollados por investigadores para resolver problemas econométricos específicos que otros lenguajes tardan más en implementar.

¿Por qué R y no Python o Julia?

Diseño para el Análisis
Su lógica vectorial permite operar sobre conjuntos de datos de forma natural y eficiente desde el primer momento.

```r
datos <- c(50, 51, 52, 53)

datos + 1
```

```
[1] 51 52 53 54
```

```julia
datos = [50, 51, 52, 53] #Julia

datos .+ 1 #Broadcasting nativo
```

```python
datos = [50, 51, 52, 53] #Python

[d + 1 for d in datos]
```

R vs. Excel

Reproducibilidad y auditoría
R permite adoptar flujos de trabajo que superan las limitaciones de las hojas de cálculo, priorizando procesos auditables y transparentes mediante el uso de código.

- **El fin de la «caja negra»:** En Excel, datos y fórmulas conviven en la misma celda. Un clic accidental puede alterar un modelo entero sin dejar rastro.
- **Auditoría transparente:** En R, los datos crudos nunca se tocan. El código funciona como un registro histórico exacto de cada paso, filtro y cálculo que aplicamos.
- **Reproducibilidad absoluta:** Si el mes que viene ingresan datos nuevos, no hay que repetir horas de trabajo manual. Se vuelve a ejecutar el script y los resultados se actualizan al instante.

R vs. Excel

Escalabilidad
Mientras que Excel colapsa con grandes volúmenes de datos, R permite gestionar eficientemente bases complejas y automatizar la producción de informes técnicos.

Prevención de Errores
En R, el proceso completo desde la importación de datos (Excel, CSV) hasta el resultado final queda registrado. En Excel, un clic equivocado en una celda puede alterar un modelo entero sin dejar rastro.

El data frame

El data frame es la estructura fundamental en R (y la vamos a estar usando prácticamente en todas las clases menos en la primera) para el manejo de información tabular, comportándose de manera muy similar a una hoja de cálculo tradicional.
Se organiza en un formato bidimensional estándar donde cada fila representa una observación individual (un registro o caso) y cada columna corresponde a una variable específica que describe esa observación.

id	sector	ventas_M	exporta	empleados	fecha
<int>	<chr>	<dbl>	<lgl>	<int>	<date>
1	"Industria"	120.5	TRUE	45	2018-03-15
2	"Servicios"	85.0	FALSE	12	2020-01-10
3	"Agro"	210.3	TRUE	8	2015-11-22
4	"Servicios"	45.8	FALSE	NA	2021-06-05
5	"Industria"	NA	TRUE	150	2010-09-01
6	"Comercio"	32.1	FALSE	5	2022-02-18
7	"Agro"	180.0	TRUE	15	2017-08-30
8	"Industria"	95.4	FALSE	28	NA
9	"Comercio"	54.2	FALSE	10	2019-12-11
⋮					

El data frame

La característica más poderosa del data frame radica en su flexibilidad para almacenar datos heterogéneos. A diferencia de las matrices clásicas que exigen un único tipo de dato, esta estructura permite combinar columnas de distintas naturalezas.
Por ejemplo, se puede tener texto en una columna, valores numéricos en otra y valores lógicos en una tercera. Esta versatilidad lo convierte en la herramienta indispensable y el estándar de facto para la importación, manipulación y análisis estadístico en R.

El data frame

Ningún usuario de R llega lejos si no conoce como operar con un data frame 👻

Empezaremos estudiando la unidad básica: los vectores
R tiene una lógica vectorial distintiva. Comenzaremos estudiando tipos de datos (numéricos, caracteres, lógicos) y estructuras básicas como los vectores.

Y finalizaremos con el data frame
Entenderemos los vectores porque un data frame (la estructura donde ocurre el análisis real) no es más que una colección de vectores (columnas) de la misma longitud.

El data frame

Características de un data frame

- Estructura tabular bidimensional (filas y columnas).
- Cada columna puede tener un tipo de dato distinto (ej. una columna numérica para «Ingresos», otra de caracteres para «Región»).
- Permite un manejo estructurado y adecuado de los valores perdidos (NA), algo vital en bases de datos reales.

Una gramática consistente

Utilizaremos el ecosistema tidyverse, específicamente el paquete `dplyr`, que propone una gramática para la manipulación de datos mediante verbos específicos.

Consultas y operaciones

Operaciones fundamentales
Aprenderemos a seleccionar columnas (select), filtrar filas (filter), ordenar (arrange), crear variables (mutate) y agregar información (summarise).

La gramática de gráficos

A diferencia del software tradicional que ofrece plantillas rígidas, ggplot2 permite construir visualizaciones complejas mediante la combinación sistemática de capas.

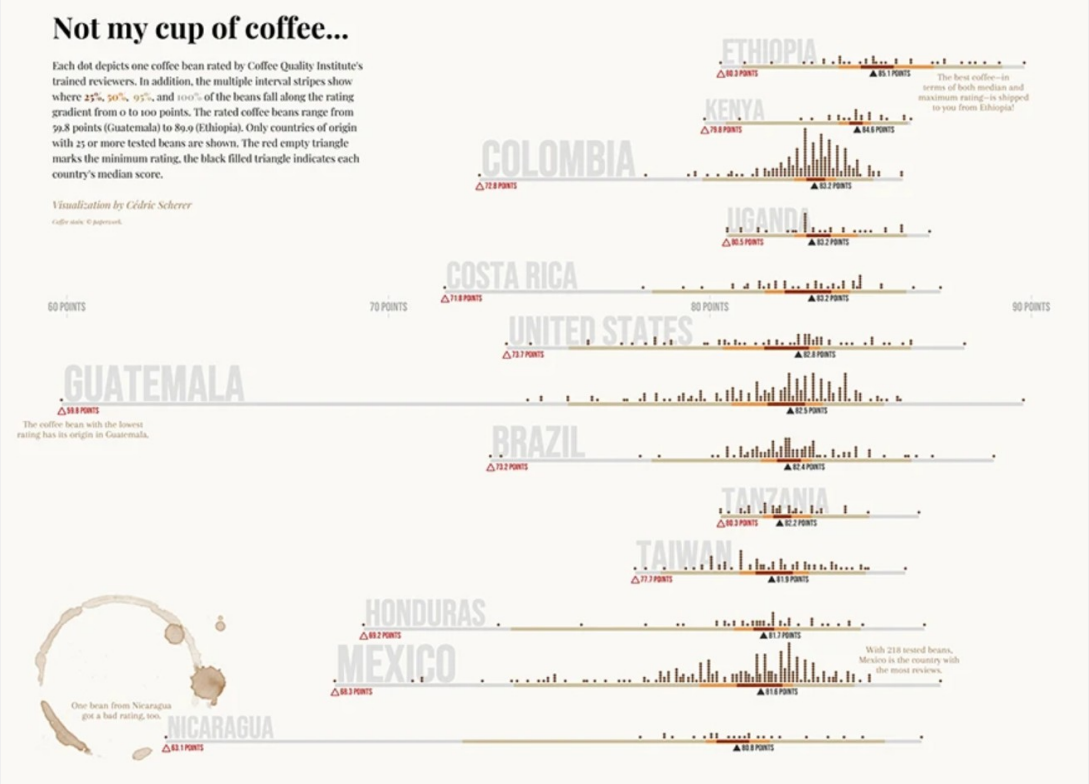

Mapeo intuitivo
Aprenderemos a vincular (mapear) las variables de nuestros Data Frames directamente a propiedades visuales, como el color, el tamaño o la forma de los elementos en el gráfico.

El fin del «copiar y pegar»
Quarto permite integrar en un mismo documento el texto narrativo (Markdown) con los bloques de código ejecutable de R. Esto vincula directamente el análisis con sus resultados, garantizando la reproducibilidad.

Automatización y parametrización
Podremos generar automáticamente múltiples versiones de un mismo análisis cambiando solo los datos de entrada o ciertas configuraciones, lo que maximiza la eficiencia y minimiza errores en actualizaciones periódicas.

Por donde empezar

Si ya querés instalar R, Rtools y RStudio te dejo **acá** un enlace a un documento del aula virtual con unas indicaciones rápidas.
También te recomiendo que empieces a familiarizarte con el aula virtual.

Nos vemos!

¿Y qué tenés que saber sobre este curso?

Carrera
Principalmente dirigido a estudiantes de la licenciatura en economía.

Régimen de cursado
Cuatrimestral

Modalidad de cursado
Presencial (sin asistencia obligatoria)

Carga horaria total
45.5 h totales: 32.5 h presenciales + 13 h autónomas.

¿Y qué tenés que saber sobre este curso?

Programa analítico

El programa se estructura en cinco ejes temáticos que articulan de manera progresiva las competencias necesarias para el análisis de datos con R.

1. Familiarización con el entorno
2. Carga de datos
3. Manipulación de datos
4. Representación de los datos
5. Generación de informes

Para más detalles sobre estos ejes, consultá el programa de la materia.

¿Y qué tenés que saber sobre este curso?

Sistema de evaluación
La evaluación se concibe como un proceso continuo e integral, estructurado en dos modalidades complementarias: formativa (seguimiento constante) y sumativa (integración de saberes).

¿Y qué tenés que saber sobre este curso?

Evaluación formativa
Al finalizar cada clase, se asignará una actividad práctica para realizar de forma asincrónica. Estas tareas consisten en ejercicios de los temas vistos en la sesión articulados con los temas de encuentros anteriores.
Se prevé una actividad por cada unidad/clase dictada.
Para más detalles sobre esto, consultá el programa de la materia.

¿Y qué tenés que saber sobre este curso?

Evaluación sumativa

En lugar de exámenes parciales fragmentados, se evaluará opcionalmente la capacidad del estudiante para articular todas las competencias de la asignatura mediante un único proyecto transversal.

Se plantea un trabajo de elaboración propia que deberá resolver una problemática compleja utilizando las herramientas adquiridas durante todo el cursado.

Para más detalles sobre esto, consultá el programa de la materia.

¿Y qué tenés que saber sobre este curso?

Condición de promoción

Para aprobar la materia deberá alcanzar 10 puntos entre todas las actividades, correspondiéndole:

- 1 punto a cada actividad semanal aprobada.
- 5 puntos por el trabajo final.

Para más detalles sobre esto...